

Большая языковая модель

Материал из Википедии — свободной энциклопедии

Большая языковая модель (БЯМ — калька с англ. large language model, LLM) — это языковая модель, состоящая из нейронной сети со множеством параметров (обычно миллиарды весовых коэффициентов и более), обученной на большом количестве неразмеченного текста с использованием обучения без учителя. БЯМ появились примерно в 2018 году и хорошо справляются с широким спектром задач. Это сместило фокус исследований обработки естественного языка с предыдущей парадигмы обучения специализированных контролируемых моделей для конкретных задач^[1].

Содержание

Характеристики

Архитектура и обучение

Применение к последующим задачам

Тонкая настройка

Подсказка

Список больших языковых моделей

Примечания

Комментарии

Источники

Характеристики

Хотя термин *большая языковая модель* не имеет формального определения, он обычно относится к моделям глубокого обучения, имеющим количество параметров порядка миллиардов и более^[2]. БЯМ — это модели общего назначения, которые превосходно справляются с широким спектром задач, в отличие от обучения одной конкретной задаче (например, анализу настроений, распознаванию именованных сущностей или математическим рассуждениям)^{[1][3]}. Несмотря на обучение на простых задачах, таких как предсказание следующего слова в предложении, нейронные языковые модели с достаточным обучением и подсчётом параметров схватывают большую часть синтаксиса и семантики человеческого языка. Кроме того, большие языковые модели демонстрируют значительные общие знания о мире и способны «запоминать» большое количество фактов во время обучения^[1].

Архитектура и обучение

В БЯМ чаще всего использовалась архитектура трансформера, которая с 2018 года стала стандартной техникой глубокого обучения для последовательных данных (ранее наиболее распространёнными были рекуррентные архитектуры, такие как модели с долгой кратковременной памятью). БЯМ обучаются без учителя на неаннотированном тексте. Трансформер при генерации вывода слева направо обучается максимизировать вероятность, назначенную следующему слову в обучающих данных, с учётом предыдущего контекста. В качестве альтернативы БЯМ может использовать *двунаправленный трансформер* (как в примере BERT), который присваивает распределение вероятностей по словам, имеющим доступ как к предыдущему, так и к последующему контексту^[4]. В дополнение к задаче прогнозирования следующего слова или «заполнения пробелов» БЯМ могут быть обучены вспомогательным задачам, которые проверяют их понимание распределения данных, таких как *прогнозирование следующего предложения* (NSP), в котором представлены пары предложений и модель должна предсказать, появятся ли они рядом в обучающем корпусе текстов^[4].

Самые ранние БЯМ обучались на корпусах, содержащих порядка миллиардов слов. Первоначальная версия GPT была обучена в 2018 году на BookCorpus, состоящем из 985 миллионов слов. В том же году BERT прошёл обучение на сочетании BookCorpus и английской Википедии, что соответствовало 3,3 миллиарда слов^[4]. С тех пор учебные корпуса для БЯМ увеличились на порядки, достигнув сотен миллиардов или триллионов токенов^[4].

Обучение БЯМ требует больших вычислительных ресурсов. Исследование 2020 года оценило стоимость обучения модели с 1,5 миллиардами параметров (на 1-2 порядка меньше, чем уровень техники в то время) в 1,6 миллиона долларов^[5].

Анализ 2020 года показал, что возможности нейронных языковых моделей (измеряемые функцией потерь при обучении) плавно увеличивались по степенному закону от количества параметров, количества обучающих данных и вычислений, используемых для обучения^{[6][7]}. Эти связи были проверены в широком диапазоне значений (до семи порядков), и не наблюдалось затухания отношения на верхнем конце диапазона (в том числе для размеров сети до триллионов параметров)^[7].

Применение к последующим задачам

В период с 2018 по 2020 год стандартный метод использования БЯМ для конкретной задачи NLP заключался в тонкой настройке модели с дополнительным обучением для конкретной задачи. Впоследствии обнаружилось, что более мощные БЯМ, такие как GPT-3, могут решать задачи без дополнительного обучения с помощью методов «подсказки», в которых решаемая задача представляется модели в виде текстовой подсказки, возможно, с некоторыми текстовыми примерами подобных задач и их решений^[1].

Тонкая настройка

Тонкая настройка — это практика модификации существующей предварительно обученной языковой модели путём её обучения (под наблюдением) конкретной задаче (например, анализ настроений, распознавание именованных объектов или маркировка частей речи). Это форма передаточного обучения. Обычно это включает введение нового набора весов, связывающих последний слой языковой модели с выходными данными последующей задачи. Исходные веса языковой модели могут быть «заморожены», так что во время обучения изучается только новый слой весов, соединяющий их с выходными данными. В качестве альтернативы исходные веса могут получать небольшие обновления (возможно, с замороженными более ранними слоями)^[4].

Подсказка

В парадигме подсказок, популяризированной GPT-3^[3], решаемая проблема формулируется с помощью текстовой подсказки, которую модель должна решить, предоставляя завершение (посредством статистического вывода). В «подсказке с несколькими выстрелами» подсказка включает небольшое количество примеров похожих пар (задача и решение). Например, задача анализа тональности маркировки тональности рецензии на фильм можно вызвать следующим образом^[3]:

Review: This movie stinks.
Sentiment: negative

Review: This movie is fantastic!
Sentiment:

Если модель выдаёт «положительно», значит, она правильно решила задачу. В подсказках с «нулевым выстрелом» примеры решения не предоставляются^{[5][8]}. Примером с нулевой подсказкой для задачи с ответом на вопрос может быть «Кто написал книгу „*Происхождение видов*“?».

Было показано, что малая производительность БЯМ позволяет достигать конкурентоспособных результатов в задачах обработки естественного языка, иногда превосходя предыдущие современные подходы к точной настройке. Примерами таких задач NLP являются перевод, ответы на вопросы, задачи с ограничениями, расшифровка слов и использование нового слова в предложении^[8]. Создание и оптимизация таких подсказок называется инжинирингом подсказок и в настоящее время является активной областью исследований.

Список больших языковых моделей

Список больших языковых моделей

Название	Дата релиза ^[a]	Разработчик	Число параметров ^[b]	Размер корпуса текстов	Лицензия ^[c]	Примечания
<u>YandexGPT</u>	2023-05-17	<u>Яндекс</u>			Proprietary	На основе YandexGPT работает виртуальный помощник «Алиса».
<u>BERT</u>	2018	<u>Google</u>	340 миллионов ^[9]	3,3 миллиарда слов ^[9]	Apache 2.0 ^[10]	Ранняя и влиятельная языковая модель ^[1] .
<u>GigaChat</u>	2023-04	<u>Сбербанк</u>			Proprietary	
<u>GPT-2</u>	2019	<u>OpenAI</u>	1,5 миллиарда ^[11]	40GB ^[12] (~10 миллиардов токенов) ^[13]	MIT ^[14]	Универсальная модель на базе трансформенной архитектуры.
<u>GPT-3</u>	2020	OpenAI	175 миллиардов ^[5]	499 миллиардов токенов ^[13]	Общедоступный веб-API	Доработанный вариант GPT-3, получивший название GPT-3.5, стал общедоступным через веб-интерфейс под названием ChatGPT в 2022 году ^[15] .
GPT-Neo	Март 2021	<u>EleutherAI</u>	2,7 миллиарда ^[16]	825 GiB ^[17]	MIT ^[18]	Первый из серии бесплатных альтернатив GPT-3, выпущенных EleutherAI. GPT-Neo превзошёл модель GPT-3 аналогичного размера в некоторых тестах, но был значительно хуже, чем самая большая GPT-3 ^[18] .
<u>GPT-J</u>	Июнь 2021	<u>EleutherAI</u>	6 миллиардов ^[19]	825 GiB ^[17]	Apache 2.0	Языковая модель в стиле GPT-3.
<u>Claude</u> ^[20]	Декабрь 2021	<u>Anthropic</u>	52 миллиарда ^[21]	400 миллиардов токенов ^[21]	Закрытая бета	Fine-tuned for desirable behavior in conversations ^[22] .
GLaM (Generalist Language Model)	Декабрь 2021	Google	1,2 триллиона ^[23]	1,6 триллиона токенов ^[23]	Proprietary	Модель с разреженной смесью экспертов (англ. <i>sparse mixture-of-experts mode</i>), что делает её более дорогой для обучения, но более дешёвой для выполнения логического вывода по сравнению с GPT-3.
<u>LaMDA</u> (Language Models for Dialog Applications)	Январь 2022	Google	137 миллиардов ^[24]	1,56Т слов ^[24]	Proprietary	Специализируется на генерации ответов в разговорах.
Megatron-Turing NLG	Октябрь 2021 ^[25]	<u>Microsoft and Nvidia</u>	530 миллиардов ^[26]	338,6 миллиарда токенов ^[26]	Restricted web access	Стандартная архитектура, но обученная на суперкомпьютерном кластере.
GPT-NeoX	Февраль 2022	<u>EleutherAI</u>	20 миллиардов ^[27]	825 GiB ^[17]	Apache 2.0	На базе архитектуры Megatron.
<u>Chinchilla</u>	Март 2022	<u>DeepMind</u>	70 миллиардов ^[28]	1,3 триллиона токенов ^[28] ^[29]	Proprietary	Модель с уменьшенным количеством параметров, обученная на большем количестве данных.

Название	Дата релиза ^[a]	Разработчик	Число параметров ^[b]	Размер корпуса текстов	Лицензия ^[c]	Примечания
PaLM (Pathways Language Model)	Апрель 2022	Google	540 миллиардов ^[30]	768 миллиардов токенов ^[28]	Proprietary	Направлена на достижение практических пределов масштаба модели.
OPT (Open Pretrained Transformer)	Май 2022	<u>Meta</u>	175 миллиардов ^[31]	180 миллиардов токенов ^[32]	Некоммерческое исследование ^[d]	Архитектура GPT-3 с некоторыми адаптациями Megatron.
YaLM 100B	Июнь 2022	<u>Яндекс</u>	100 миллиардов ^[33]	300 миллиардов токенов ^[34]	Apache 2.0	75 % текста, использованного при обучении, написано на русском языке ^[34] .
<u>BLOOM</u>	Июль 2022	Коллаборация под управлением <u>Hugging Face</u>	175 миллиардов ^[6]	350 миллиардов токенов (1,6TB) ^[35]	Responsible AI	По сути — GPT-3, но обучена многоязычному корпусу текстов (30 % английский, исключая языки программирования).
AlexaTM (Teacher Models)	Ноябрь 2022	<u>Amazon</u>	20 миллиардов ^[36]	1,3 триллиона ^[37]	Общедоступный веб-API ^[38]	Двунаправленная архитектура «последовательность к последовательности».
LLaMA (Large Language Model Meta AI)	Февраль 2023	<u>Meta</u>	65 миллиардов ^[39]	1,4 триллиона ^[39]	Некоммерческое исследование ^[e]	Обучена на большом корпусе из 20 языков, чтобы добиться лучшей производительности с меньшим количеством параметров ^[39] .
<u>GPT-4</u>	Март 2023	OpenAI	Нет данных ^[f]	Нет данных	Общедоступный веб-API	Доступна для пользователей ChatGPT Plus. Microsoft подтвердила, что в Bing Chat используется модель GPT-4 ^[41] .
StableLM	Апрель 2023	Stability-AI	7 миллиардов ^[42]	800 миллиардов ^[42]	Исходный код: Apache 2.0 ^[42]	

Примечания

Комментарии

- а. Это дата первого появления документации, описывающей архитектуру модели.
- б. Во многих случаях исследователи публикуют или сообщают о нескольких версиях модели, имеющих разные размеры. В этих случаях здесь указывается размер самой большой модели.
- с. Это лицензия весов предварительно обученной модели. Почти во всех случаях сам обучающий код имеет открытый исходный код или может быть легко воспроизведён.
- д. Меньшие модели, включая 66B, общедоступны, а модель 175B доступна по запросу.
- е. Лицензия Facebook и схема распространения ограничивали доступ к утвержденным исследователям, но веса моделей утекли и стали широко доступны.
- ф. Как указано в техническом отчёте: «Учитывая конкурентную среду и последствия для безопасности крупномасштабных моделей, таких как GPT-4, этот отчёт не содержит дополнительных сведений об архитектуре (включая размер модели), оборудовании, обучающих вычислениях, построении набора данных, методе обучения, или подобную информацию»^[40].

Источники

1. Manning, Christopher D. (2022). "Human Language Understanding & Reasoning" (<https://www.amacad.org/publication/human-language-understanding-reasoning>). *Daedalus*. Архивировано (<https://web.archive.org/web/20231117205531/https://www.amacad.org/publication/human-language-understanding-reasoning>) 17 ноября 2023. Дата обращения: 16 марта 2023.
2. Carlini, Nicholas; Tramer, Florian; Wallace, Eric; Jagielski, Matthew; Herbert-Voss, Ariel; Lee, Katherine; Roberts, Adam; Brown, Tom B; Song, Dawn; Erlingsson, Ulfar (2021). *Extracting Training Data from Large Language Models* (<https://www.usenix.org/system/files/sec21-carlini-extracting.pdf>) (PDF). USENIX Security Symposium. Vol. 6. Архивировано (<https://web.archive.org/web/20231221210608/https://www.usenix.org/system/files/sec21-carlini-extracting.pdf>) (PDF) 21 декабря 2023. Дата обращения: 16 марта 2023.
3. Wei, Jason Emergent Abilities of Large Language Models (<https://arxiv.org/abs/2206.07682>). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230316140558/https://arxiv.org/abs/2206.07682>) 16 марта 2023 года.
4. Jurafsky, Dan. Speech and Language Processing (https://web.stanford.edu/~jurafsky/slp3/ed3book_jan72023.pdf) / Dan Jurafsky, James H. Martin. — 3rd edition draft. — 2023-01-07. Архивная копия (https://web.archive.org/web/20230323210221/https://web.stanford.edu/~jurafsky/slp3/ed3book_jan72023.pdf) от 23 марта 2023 на Wayback Machine
5. Wiggers, Kyle The emerging types of language models and why they matter (<https://techcrunch.com/2022/04/28/the-emerging-types-of-language-models-and-why-they-matter/>). *TechCrunch* (28 апреля 2022). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230316072443/https://techcrunch.com/2022/04/28/the-emerging-types-of-language-models-and-why-they-matter/>) 16 марта 2023 года.
6. Ananthaswamy, Anil In AI, is bigger always better? (<https://www.nature.com/articles/d41586-023-00641-w>) *Nature* (8 марта 2023). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230316181013/https://www.nature.com/articles/d41586-023-00641-w>) 16 марта 2023 года.
7. Kaplan, Jared; McCandlish, Sam; Henighan, Tom; Brown, Tom B.; Chess, Benjamin; Child, Rewon; Gray, Scott; Radford, Alec; Wu, Jeffrey; Amodei, Dario (2020). "Scaling Laws for Neural Language Models" (<https://arxiv.org/abs/2001.08361>). *CoRR*. abs/2001.08361. arXiv:2001.08361 (<https://arxiv.org/abs/2001.08361>). Архивировано (<https://web.archive.org/web/20230315213534/https://arxiv.org/abs/2001.08361>) 15 марта 2023. Дата обращения: 16 марта 2023.
8. Brown, Tom B.; Mann, Benjamin; Ryder, Nick; Subbiah, Melanie; Kaplan, Jared; Dhariwal, Prafulla; Neelakantan, Arvind; Shyam, Pranav; Sastry, Girish; Askell, Amanda; Agarwal, Sandhini; Herbert-Voss, Ariel; Krueger, Gretchen; Henighan, Tom; Child, Rewon; Ramesh, Aditya; Ziegler, Daniel M.; Wu, Jeffrey; Winter, Clemens; Hesse, Christopher; Chen, Mark; Sigler, Eric; Litwin, Mateusz; Gray, Scott; Chess, Benjamin; Clark, Jack; Berner, Christopher; McCandlish, Sam; Radford, Alec; Sutskever, Ilya; Amodei, Dario (Dec 2020). Larochelle, H.; Ranzato, M.; Hadsell, R.; Balcan, M.F.; Lin, H. (eds.). "Language Models are Few-Shot Learners" (<https://proceedings.neurips.cc/paper/2020/file/1457c0d6b6bcb4967418bfb8ac142f64a-Paper.pdf>) (PDF). *Advances in Neural Information Processing Systems*. **33**. Curran Associates, Inc.: 1877—1901. Архивировано (<https://web.archive.org/web/20231117204007/https://proceedings.neurips.cc/paper/2020/file/1457c0d6b6bcb4967418bfb8ac142f64a-Paper.pdf>) (PDF) 17 ноября 2023. Дата обращения: 16 марта 2023.
9. Devlin, Jacob; Chang, Ming-Wei; Lee, Kenton; Toutanova, Kristina (2018-10-11). "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". arXiv:1810.04805v2 (<https://arxiv.org/abs/1810.04805v2>) [cs.CL (<https://arxiv.org/archive/cs>)].
10. BERT (<https://github.com/google-research/bert>) (13 марта 2023). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20210113211317/https://github.com/google-research/bert>) 13 января 2021 года.
11. GPT-2: 1.5B Release (<https://openai.com/blog/gpt-2-1-5b-release/>) (англ.). *OpenAI* (5 ноября 2019). Дата обращения: 14 ноября 2019. Архивировано (<https://web.archive.org/web/20191114074358/https://openai.com/blog/gpt-2-1-5b-release/>) 14 ноября 2019 года.
12. Better language models and their implications (<https://openai.com/research/better-language-models>). *openai.com*. Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230316160730/https://openai.com/research/better-language-models>) 16 марта 2023 года.
13. OpenAI's GPT-3 Language Model: A Technical Overview (<https://lambdalabs.com/blog/demystifying-gpt-3>) (англ.). *lambdalabs.com*. Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230327213811/https://lambdalabs.com/blog/demystifying-gpt-3>) 27 марта 2023 года.
14. gpt-2 (<https://github.com/openai/gpt-2>). *GitHub*. Дата обращения: 13 марта 2023. Архивировано (<https://web.archive.org/web/20230311154936/https://github.com/openai/gpt-2>) 11 марта 2023 года.
15. ChatGPT: Optimizing Language Models for Dialogue (<https://openai.com/blog/chatgpt/>) (англ.). *OpenAI* (30 ноября 2022). Дата обращения: 13 января 2023. Архивировано (<https://web.archive.org/web/20221130180912/https://openai.com/blog/chatgpt/>) 30 ноября 2022 года.
16. GPT Neo (<https://github.com/EleutherAI/gpt-neo>) (15 марта 2023). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230312225202/https://github.com/EleutherAI/gpt-neo>) 12 марта 2023 года.

17. Gao, Leo; Biderman, Stella; Black, Sid; Golding, Laurence; Hoppe, Travis; Foster, Charles; Phang, Jason; He, Horace; Thite, Anish; Nabeshima, Noa; Presser, Shawn; Leahy, Connor (2020-12-31). "The Pile: An 800GB Dataset of Diverse Text for Language Modeling". arXiv:2101.00027 (<https://arxiv.org/abs/2101.00027>).
18. Iyer, Abhishek GPT-3's free alternative GPT-Neo is something to be excited about (<https://venturebeat.com/ai/gpt-3s-free-alternative-gpt-neo-is-something-to-be-excited-about/>). *VentureBeat* (15 мая 2021). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230309012717/http://venturebeat.com/ai/gpt-3s-free-alternative-gpt-neo-is-something-to-be-excited-about/>) 9 марта 2023 года.
19. GPT-J-6B: An Introduction to the Largest Open Source GPT Model | Forefront (<https://web.archive.org/web/20230309205439/https://www.forefront.ai/blog-posts/gpt-j-6b-an-introduction-to-the-largest-open-sourced-gpt-model>) (англ.). *www.forefront.ai*. Дата обращения: 28 февраля 2023. Архивировано из оригинала (<https://www.forefront.ai/blog-posts/gpt-j-6b-an-introduction-to-the-largest-open-sourced-gpt-model>) 9 марта 2023 года.
20. Product (<https://www.anthropic.com/product>) (англ.). *Anthropic*. Дата обращения: 14 марта 2023. Архивировано (<https://web.archive.org/web/20230316145444/https://www.anthropic.com/product>) 16 марта 2023 года.
21. Askell, Amanda; Bai, Yuntao; Chen, Anna; et al. (2021-12-09). "A General Language Assistant as a Laboratory for Alignment". arXiv:2112.00861 (<https://arxiv.org/abs/2112.00861>).
22. Bai, Yuntao; Kadavath, Saurav; Kundu, Sandipan; et al. (2022-12-15). "Constitutional AI: Harmlessness from AI Feedback". arXiv:2212.08073 (<https://arxiv.org/abs/2212.08073>).
23. Dai, Andrew M; Du, Nan More Efficient In-Context Learning with GLaM (<https://ai.googleblog.com/2021/12/more-efficient-in-context-learning-with.html>) (англ.). *ai.googleblog.com* (9 декабря 2021). Дата обращения: 9 марта 2023. Архивировано (<https://web.archive.org/web/20230312072042/https://ai.googleblog.com/2021/12/more-efficient-in-context-learning-with.html>) 12 марта 2023 года.
24. Cheng, Heng-Tze; Thoppilan, Romal LaMDA: Towards Safe, Grounded, and High-Quality Dialog Models for Everything (<https://ai.googleblog.com/2022/01/lamda-towards-safe-grounded-and-high.html>) (англ.). *ai.googleblog.com* (21 января 2022). Дата обращения: 9 марта 2023. Архивировано (<https://web.archive.org/web/20220325014118/https://ai.googleblog.com/2022/01/lamda-towards-safe-grounded-and-high.html>) 25 марта 2022 года.
25. Alvi, Ali; Kharya, Paresh Using DeepSpeed and Megatron to Train Megatron-Turing NLG 530B, the World's Largest and Most Powerful Generative Language Model (<https://www.microsoft.com/en-us/research/blog/using-deepspeed-and-megatron-to-train-megatron-turing-nlg-530b-the-worlds-largest-and-most-powerful-generative-language-model/>). *Microsoft Research* (11 октября 2021). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230313180531/https://www.microsoft.com/en-us/research/blog/using-deepspeed-and-megatron-to-train-megatron-turing-nlg-530b-the-worlds-largest-and-most-powerful-generative-language-model/>) 13 марта 2023 года.
26. Smith, Shaden; Patwary, Mostofa; Norick, Brandon; LeGresley, Patrick; Rajbhandari, Samyam; Casper, Jared; Liu, Zhun; Prabhunoye, Shrimai; Zerveas, George; Korthikanti, Vijay; Zhang, Elton; Child, Rewon; Aminabadi, Reza Yazdani; Bernauer, Julie; Song, Xia (2022-02-04). "Using DeepSpeed and Megatron to Train Megatron-Turing NLG 530B, A Large-Scale Generative Language Model". arXiv:2201.11990 (<https://arxiv.org/abs/2201.11990>) Архивная копия (<https://web.archive.org/web/20230415083726/https://arxiv.org/abs/2201.11990>) от 15 апреля 2023 на Wayback Machine
27. Black, Sidney; Biderman, Stella; Hallahan, Eric; et al. (2022-05-01). *GPT-NeoX-20B: An Open-Source Autoregressive Language Model* (<https://aclanthology.org/2022.bigscience-1.9/>). Proceedings of BigScience Episode #5 -- Workshop on Challenges & Perspectives in Creating Large Language Models. Vol. Proceedings of BigScience Episode #5 -- Workshop on Challenges & Perspectives in Creating Large Language Models. pp. 95—136. Архивировано (<https://web.archive.org/web/20221210082456/https://aclanthology.org/2022.bigscience-1.9/>) 10 декабря 2022. Дата обращения: 19 декабря 2022.
28. Hoffmann, Jordan; Borgeaud, Sebastian; Mensch, Arthur; Sifre, Laurent An empirical analysis of compute-optimal large language model training (<https://www.deepmind.com/blog/an-empirical-analysis-of-compute-optimal-large-language-model-training>). *Deepmind Blog* (12 апреля 2022). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20220413014510/https://www.deepmind.com/blog/an-empirical-analysis-of-compute-optimal-large-language-model-training>) 13 апреля 2022 года.
29. Hoffmann, Jordan; Borgeaud, Sebastian; Mensch, Arthur; Buchatskaya, Elena; Cai, Trevor; Rutherford, Eliza; Casas, Diego de Las; Hendricks, Lisa Anne; Welbl, Johannes; Clark, Aidan; Hennigan, Tom; Noland, Eric; Millican, Katie; Driessche, George van den; Damoc, Bogdan; Guy, Aurelia; Osindero, Simon; Simonyan, Karen; Elsen, Erich; Rae, Jack W.; Vinyals, Oriol; Sifre, Laurent (2022-03-29). "Training Compute-Optimal Large Language Models". arXiv:2203.15556 (<https://arxiv.org/abs/2203.15556>)

30. *Narang, Sharan; Chowdhery, Aakanksha Pathways Language Model (PaLM): Scaling to 540 Billion Parameters for Breakthrough Performance* (<https://ai.googleblog.com/2022/04/pathways-language-model-palm-scaling-to.html>) (англ.). *ai.googleblog.com* (4 апреля 2022). Дата обращения: 9 марта 2023. Архивировано (<https://web.archive.org/web/20220404161447/https://ai.googleblog.com/2022/04/pathways-language-model-palm-scaling-to.html>) 4 апреля 2022 года.
31. *Democratizing access to large-scale language models with OPT-175B* (<https://ai.facebook.com/blog/democratizing-access-to-large-scale-language-models-with-opt-175b/>) (англ.). *ai.facebook.com*. Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230312231820/https://ai.facebook.com/blog/democratizing-access-to-large-scale-language-models-with-opt-175b/>) 12 марта 2023 года.
32. Zhang, Susan; Roller, Stephen; Goyal, Naman; Artetxe, Mikel; Chen, Moya; Chen, Shuohui; Dewan, Christopher; Diab, Mona; Li, Xian; Lin, Xi Victoria; Mihaylov, Todor; Ott, Myle; Shleifer, Sam; Shuster, Kurt; Simig, Daniel; Koura, Punit Singh; Sridhar, Anjali; Wang, Tianlu; Zettlemoyer, Luke (2022-06-21). "OPT: Open Pre-trained Transformer Language Models". *arXiv:2205.01068* (<https://arxiv.org/abs/2205.01068>).
33. Источник (<https://yandex.ru/company/news/2022-06-23/>). Дата обращения: 20 июля 2023. Архивировано (<https://web.archive.org/web/20230720172751/https://yandex.ru/company/news/2022-06-23/>) 20 июля 2023 года.
34. GitHub — *yandex/YaLM-100B: Pretrained language model with 100B parameters* (<https://github.com/yandex/YaLM-100B>). Дата обращения: 20 июля 2023. Архивировано (<https://web.archive.org/web/20230616050056/https://github.com/yandex/YaLM-100B>) 16 июня 2023 года.
35. *bigscience/bloom* · Hugging Face (<https://huggingface.co/bigscience/bloom>). *huggingface.co*. Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230412002547/https://huggingface.co/bigscience/bloom>) 12 апреля 2023 года.
36. 20B-parameter Alexa model sets new marks in few-shot learning (<https://www.amazon.science/blog/20b-parameter-alexa-model-sets-new-marks-in-few-shot-learning>) (англ.). *Amazon Science* (2 августа 2022). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230315190223/https://www.amazon.science/blog/20b-parameter-alexa-model-sets-new-marks-in-few-shot-learning>) 15 марта 2023 года.
37. Soltan, Saleh; Ananthakrishnan, Shankar; FitzGerald, Jack; et al. (2022-08-03). "AlexaTM 20B: Few-Shot Learning Using a Large-Scale Multilingual Seq2Seq Model". *arXiv:2208.01448* (<https://arxiv.org/abs/2208.01448>).
38. *AlexaTM 20B is now available in Amazon SageMaker JumpStart | AWS Machine Learning Blog* (<https://aws.amazon.com/blogs/machine-learning/alexatm-20b-is-now-available-in-amazon-sagemaker-jumpstart/>). *aws.amazon.com* (17 ноября 2022). Дата обращения: 13 марта 2023. Архивировано (<https://web.archive.org/web/20230313163933/https://aws.amazon.com/blogs/machine-learning/alexatm-20b-is-now-available-in-amazon-sagemaker-jumpstart/>) 13 марта 2023 года.
39. *Introducing LLaMA: A foundational, 65-billion-parameter large language model* (<https://ai.facebook.com/blog/large-language-model-llama-meta-ai/>). *Meta AI* (24 февраля 2023). Дата обращения: 16 марта 2023. Архивировано (<https://web.archive.org/web/20230303112302/https://ai.facebook.com/blog/large-language-model-llama-meta-ai/>) 3 марта 2023 года.
40. *GPT-4 Technical Report* (<https://cdn.openai.com/papers/gpt-4.pdf>). *OpenAI* (2023). Дата обращения: 14 марта 2023. Архивировано (<https://web.archive.org/web/20230314190904/https://cdn.openai.com/papers/gpt-4.pdf>) 14 марта 2023 года.
41. *Lardinois, Frederic Microsoft’s new Bing was using GPT-4 all along* (<https://techcrunch.com/2023/03/14/microsofts-new-bing-was-using-gpt-4-all-along/>). *TechCrunch* (14 марта 2023). Дата обращения: 14 марта 2023. Архивировано (<https://web.archive.org/web/20230315013650/https://techcrunch.com/2023/03/14/microsofts-new-bing-was-using-gpt-4-all-along/>) 15 марта 2023 года.
42. *StableLM: Stability AI Language Models* (<https://github.com/Stability-AI/StableLM>). — 2023-04-20. Архивировано (<https://web.archive.org/web/20230420015951/https://github.com/Stability-AI/StableLM>) 20 апреля 2023 года.

Источник — https://ru.wikipedia.org/w/index.php?title=Большая_языковая_модель&oldid=140607882

Эта страница в последний раз была отредактирована 5 октября 2024 в 22:57.

Текст доступен по лицензии Creative Commons «С указанием авторства — С сохранением условий» (CC BY-SA); в отдельных случаях могут действовать дополнительные условия.
Wikipedia® — зарегистрированный товарный знак некоммерческой организации «Фонд Викимедиа» (Wikimedia Foundation, Inc.)